Clerkship

PROYECTO DE GRADO II · INGENIERÍA DE SISTEMAS · UNAB

Guion de la exposición y preguntas del jurado

Qué decir en cada una de las 18 diapositivas, en unos 18 minutos, y las preguntas más probables con una respuesta sugerida.

AUTORES

Juan Camilo Rojas Guerrero
Santiago Steven Arias Estupiñán
Camilo Andrés Bueno Rey

DIRECCIÓN

Leonardo Stiven Pardo Niño · Director
Luis Felipe Buitrago Castro · Codirector

VERSIÓN

28 de octubre de 2026

ANTES DE EMPEZAR

Cómo usar el guion

Cada expositor presenta una parte completa y el cambio de voz coincide con el cambio de tema. El reparto es una propuesta: cambien los nombres si prefieren otro orden.

PARTE	DIAPOSITIVAS	EXPOSITOR	TIEMPO
1. Problema, objetivo y solución	1 a 4	[Expositor A]	4 min
2. Arquitectura, frontend, backend y seguridad	5 a 8	[Expositor B]	4 min
3. La IA y la simulación	9 a 13	[Expositor C]	5 min
4. Resultados, aula, validación y cierre	14 a 18	[Expositor A] y todos al cierre	5 min

- Lo resaltado en *gris* es para decirlo casi textual; el resto, con sus palabras.
- Las notas de cada diapositiva traen la versión corta de este guion.
- Ante una pregunta que no sepan, digan qué hace hoy el prototipo y qué quedaría por medir. No inventen cifras.

PARTE 1 · 4 MINUTOS

Problema, objetivo y solución

1 **Portada** 30 s

Buenos días. Somos Juan Camilo Rojas, Santiago Arias y Camilo Bueno, y les presentamos Clerkship. Clerkship es un consultorio de práctica: el estudiante atiende a un paciente que no existe, generado por inteligencia artificial, y la plataforma califica cómo razonó, no solo si acertó el diagnóstico. Agradecer al director, Leonardo Pardo, y al codirector, Luis Felipe Buitrago.

2 **El problema** 1 min

Los errores diagnósticos son una fuente mayor de daño evitable, y en cerca del 75 % hay un fallo cognitivo: cerrar la hipótesis antes de tiempo, anclarse en un dato, sintetizar mal. *El razonamiento clínico se aprende por imitación y casi sin retroalimentación sobre el proceso.* En el programa de Medicina de la UNAB no hay un espacio para entrenarlo y evaluarlo. Los simuladores comerciales miran el diagnóstico final, están en inglés y sus licencias son caras.

3 Objetivo 1 min

Leer la pregunta problema: *¿cómo contribuir al entrenamiento y la evaluación del razonamiento clínico en estudiantes de la UNAB con un prototipo de casos clínicos basado en IA?* El objetivo general se divide en cuatro: caracterizar el dominio gastrointestinal, diseñar, implementar y evaluar. Los tres primeros están cumplidos; la evaluación está en curso: las métricas técnicas ya se midieron y falta la validación por expertos.

4 La solución 1 min 30 s

Tres pilares. El simulador, que es el núcleo. El aula virtual, parecida a Moodle, para que el docente organice su curso alrededor de las simulaciones. Y la biblioteca, con 433 recursos de gastroenterología de acceso abierto. *Todo está integrado y funciona de extremo a extremo.* Cierre de la parte: «Ahora [Expositor B] les cuenta cómo está construido».

PARTE 2 · 4 MINUTOS

Arquitectura, frontend, backend y seguridad

5 **Arquitectura** 1 min

Tres capas, cada una en su nube. El frontend en React se sirve desde Vercel. Todo pasa por una API en Flask, empaquetada en Docker y desplegada en Google Cloud Run, que se publica sola en cada cambio a la rama principal. *Usamos persistencia políglota:* PostgreSQL en Supabase para lo estructurado (usuarios, roles, cursos, notas), MongoDB Atlas para las conversaciones y evaluaciones del simulador, y Cloudflare R2 para los archivos. Los servicios externos son la API de Gemini, Mailgun para los correos y Gotenberg para convertir Office a PDF.

6 **Frontend** 1 min

React 19 con TypeScript: *el tipado evita errores silenciosos en estructuras complejas como un caso clínico o el desglose de un puntaje.* Vite para compilar y React Router 7 para las rutas, con guardas por rol y por consentimiento. Los estilos son CSS propio por módulo, con la paleta de Clerkship y modo claro y oscuro. PDF, Word, Excel y video se ven en el navegador. Al cargar cada pantalla solo cuando se abre, el paquete inicial bajó de 3,1 MB a unos 200 KB. Hay pruebas de extremo a extremo con Playwright por cada rol.

7 **Backend** 1 min

Flask organizado por módulos. Cada petición se valida con Pydantic antes de ejecutar cualquier lógica. El esquema de la base cambia con migraciones de Alembic, todas aditivas y con un espejo en SQL. *Tenemos 848 pruebas automatizadas aprobadas y 216 rutas, y una prueba falla si alguna queda sin control de rol o de propiedad.* Cada ruta está documentada en OpenAPI.

8 **Seguridad y datos** 1 min

Sesión con dos tokens JWT, uno de acceso de corta duración y uno de renovación. *A diferencia de un JWT común, en cada petición revisamos si el token fue revocado, si la cuenta sigue activa y si el rol del token es el rol actual.* Además del rol, cada ruta comprueba que el recurso sea de quien lo pide. Hay límites de peticiones, contraseñas con hash y HTML sanitizado en el servidor y en el navegador. Por la Ley 1581, el consentimiento se registra en el servidor con fecha y versión, y cada usuario puede descargar sus datos. Solo se registran correos @unab.edu.co. Cierre: «Ahora, el corazón del proyecto: la IA».

PARTE 3 · 5 MINUTOS

La IA y la simulación

9 La idea central 30 s

Leer la diapositiva: *la IA crea el caso, actúa de paciente y clasifica; la nota la pone una fórmula.* Usamos IA generativa para lo que hace bien, escribir y conversar, y reglas programadas para lo que debe ser confiable. No entrenamos ningún modelo: consumimos la API de Gemini con instrucciones especializadas.

10 Los tres agentes 1 min 30 s

El Agente 1, el generador, actúa una vez al iniciar: recibe el subtema y la dificultad (los elige el estudiante o la selección adaptativa según su desempeño) y escribe el caso completo en JSON, con antecedentes, síntomas, signos vitales, hallazgos, datos que el paciente solo revela si se le pregunta, el diagnóstico real y la rúbrica. El Agente 2 es el paciente: en cada turno recibe sus instrucciones y toda la conversación, porque el modelo no tiene memoria, y *responde sin conocer su diagnóstico*. El Agente 3, el evaluador, actúa al cerrar: compara la consulta con la rúbrica y clasifica, pero no pone nota. Los hallazgos del examen físico y de los paraclínicos también los escribe el generador al crear el caso; cuando el estudiante los pide, el sistema solo los lee del caso, sin volver a llamar al modelo: responden al instante, son consistentes y no gastan tokens. Si la maniobra toca al paciente, el Agente 2 reacciona en el chat.

11 Una consulta 1 min

Recorrer la captura: el chat en el centro (en la mayoría de casos el paciente entra diciendo su motivo de consulta, a petición del docente), el examen físico a la izquierda, las notas de la anamnesis a la derecha. El estudiante pide paraclínicos, cierra con diagnóstico, diferenciales y plan, y recibe su nota con retroalimentación. En el historial puede releer todo y ver el diagnóstico real.

12 La calificación 1 min

El evaluador entrega una clasificación (por ejemplo, concordancia de la hipótesis alta, media, baja o nula) y el archivo scoring.py la convierte en puntaje: anamnesis 30 %, razonamiento clínico 25 %, hallazgos clave 20 %, examen físico y paraclínicos 15 % y comunicación 10 %. Dentro del razonamiento, la hipótesis pesa 60 %, los diferenciales 25 % y el plan 15 %. *Así la nota es reproducible y auditable, y por eso podemos medir su consistencia.*

13 Confiabilidad 1 min

Cada respuesta del paciente pasa por dos guardas programadas: si nombra el diagnóstico o rompe el personaje, se reemplaza antes de mostrarla. El caso del generador se valida campo por campo. Y la latencia: el modelo configurado al principio tardaba unos 30 segundos por respuesta; rehicimos la cadena con Gemini 3.6 Flash y cuatro respaldos, con tiempo máximo por intento y una pausa al modelo que agota su cuota. *La evaluación pasó de unos 100 segundos a menos de 10.*

PARTE 4 · 5 MINUTOS

Resultados, aula, validación y cierre

14 Resultados técnicos 1 min 30 s

El 17 de octubre medimos con los agentes reales las variables técnicas de la sección 7.5. Robustez: 24 mensajes preparados para sacarle el diagnóstico al paciente o sacarlo de su papel; no lo logramos en ninguno. Consistencia: cinco consultas evaluadas tres veces con el mismo cierre; las cinco variaron 10 puntos o menos, y la diferencia máxima fue 6. Latencia: percentil 90 de 4,7 s en el chat y 8,0 s en la evaluación. *Decir las reservas antes de que las pregunten:* la corrida la atendieron los modelos ligeros porque se agotó la cuota gratuita, la detección de fuga busca el nombre del diagnóstico y los mensajes los preparó el equipo.

15 Aula virtual y biblioteca 1 min

El docente crea su curso, lo organiza en módulos y publica documentos, videos, tareas, cuestionarios y avisos; califica con rúbrica y exporta las notas. Cada tarea tiene una conversación privada entre docente y estudiante. La biblioteca tiene 433 recursos con visor, lápiz, notas y favoritos. La vista de seguimiento le muestra al docente el promedio por subtema y alerta a quien está por debajo de 60.

16 Validación por expertos 1 min

El administrador invita a cada profesional con un enlace personal, sin crear cuenta. El experto califica 32 ítems de 1 a 4 y da un juicio de aplicabilidad; con eso calculamos la V de Aiken con su intervalo de confianza y el I-CVI. Además revisa consultas reales anonimizadas: *primero fija su propio puntaje sin ver el de la plataforma*, y luego comparamos ambos con Bland-Altman. *A hoy no hay respuestas reales: es la prioridad de la etapa final.*

17 Límites 1 min

La rúbrica la escribe el mismo modelo que genera el caso, por eso la revisión experta es clave. La búsqueda vectorial no se implementó: hay referencias clínicas por subtema y una herramienta para cargarlas, pero falta el contenido curado. Con la cuota gratuita, las llamadas simultáneas pasan a modelos ligeros. Siguientes pasos: el panel de expertos y las pruebas con estudiantes.

18 Cierre 30 s

Clerkship funciona de extremo a extremo, sus metas técnicas se cumplieron y tiene listo el instrumento para que los expertos clínicos lo validen. Muchas gracias; quedamos atentos a sus preguntas.

PREGUNTAS PROBABLES

Sobre la IA y la simulación

1 ¿Por qué Gemini y no otro modelo?

No requiere GPU ni entrenamiento, entrega salida estructurada en JSON y tiene una cuota gratuita suficiente para un prototipo. El modelo es un parámetro de configuración: la cadena admite varios modelos de Gemini y OpenRouter como respaldo, así que cambiar de proveedor no obliga a reescribir los agentes.

2 ¿Cómo controlan las alucinaciones clínicas?

Con capas: el JSON del caso se valida campo por campo, el paciente pasa por guardas, la nota la calcula una fórmula y no el modelo. Lo que aún no está resuelto es que la rúbrica la escribe el mismo modelo que genera el caso; por eso construimos la revisión de casos por expertos.

3 ¿Qué pasa si el paciente revela el diagnóstico?

Una guarda programada revisa cada respuesta y, si nombra el diagnóstico, la reemplaza antes de mostrarla. En 24 intentos diseñados para lograrlo no se filtró ninguno. Límite: la guarda busca el nombre; una descripción indirecta de la enfermedad no se detecta.

4 ¿Por qué no dejan que la IA ponga la nota?

Porque una nota del modelo no es reproducible ni auditable. El modelo clasifica (qué cubrió, qué omitió) y una fórmula con pesos fijos calcula el puntaje. Eso permitió medir la consistencia: cinco consultas evaluadas tres veces variaron 10 puntos o menos.

5 ¿Cómo recuerda el paciente lo que ya dijo?

El modelo no tiene memoria entre llamadas. El servidor guarda el caso y la conversación y, en cada turno, le envía al paciente sus instrucciones y toda la conversación previa.

6 ¿Cuánto consume una consulta?

Según nuestra estimación, entre 18.000 y 27.000 tokens una consulta corta, entre 34.000 y 48.000 una típica y entre 80.000 y 105.000 una larga. El paciente consume entre el 66 % y el 91 %, porque su entrada crece con cada turno. Son estimaciones con una muestra pequeña, no mediciones de uso real.

7 ¿Qué es la selección adaptativa?

Si el estudiante no elige subtema, el sistema propone el de su promedio más bajo. Con tres o más casos en un subtema, el historial le recomienda qué reforzar y en qué dimensión.

8 ¿Por qué no usaron LangGraph ni búsqueda vectorial, como decía el anteproyecto?

El diseño inicial cambió al implementar: tres agentes con funciones claras y reglas programadas resultaron más simples de controlar y de probar. El documento lo declara en una tabla de diseño inicial frente a lo implementado. La búsqueda vectorial queda como trabajo futuro; hoy hay referencias clínicas por subtema.

9 ¿Y si Gemini no responde?

Cada intento tiene un tiempo máximo, y si un modelo falla se pasa al siguiente de una cadena de cinco y luego a OpenRouter. Si nada responde, no se guarda nada a medias y la pantalla reintenta.

10 ¿Los pacientes son reales?

No. Los casos son sintéticos, generados por el modelo, y la identidad del paciente es ficticia. Ningún dato de pacientes reales entra al sistema.

PREGUNTAS PROBABLES

Sobre backend, frontend, datos y seguridad

1 ¿Por qué Flask?

Es ligero y maduro, y exponer los agentes como rutas REST no necesitaba más. La validación la aporta Pydantic, y la organización, los blueprints por módulo.

2 ¿Por qué tres bases de datos?

Cada dato va donde mejor se maneja: PostgreSQL para lo que necesita integridad y relaciones (usuarios, roles, cursos, notas); MongoDB para documentos de forma variable, como la conversación y la evaluación de cada consulta; R2 para archivos grandes, que se suben y descargan con enlaces firmados sin pasar por el servidor.

3 ¿Cómo escala?

Cloud Run levanta más contenedores según la demanda y Vercel sirve el frontend desde una CDN. Los archivos de hasta 2 GB van directo del navegador a R2. El límite real hoy es la cuota de la API de Gemini: para un grupo grande se necesita un plan pago.

4 ¿Cómo evitan que un estudiante vea datos de otro?

Además del rol, cada ruta comprueba que el recurso sea de quien lo pide, y responde 404 sin revelar si existe. Un script inventaría las 216 rutas y una prueba falla si aparece una sin control.

5 ¿Qué pasa si alguien roba un token?

El token de acceso vence pronto. En cada petición se revisa si fue revocado, si la cuenta está activa y si el rol es el actual. Cerrar sesión revoca los tokens, y cambiar la contraseña o el rol corta todas las sesiones.

6 ¿Cómo cumplen la Ley 1581 de 2012?

El consentimiento informado se registra en el servidor con fecha y versión, y debe aceptarse antes de usar la plataforma. Cada usuario puede descargar una copia de sus datos. Los casos son sintéticos y, en la revisión por expertos, el nombre del estudiante se oculta incluso dentro de la conversación.

7 ¿Cómo prueban el sistema?

848 pruebas automatizadas del backend, pruebas de contrato contra la especificación OpenAPI, una revisión automática de seguridad de rutas, pruebas de extremo a extremo con Playwright y un script que mide con los agentes reales las variables de la sección 7.5.

8 ¿Por qué React y CSS propio, sin framework de estilos?

React tiene el ecosistema más amplio y TypeScript evita errores en datos complejos. El CSS propio da control total sobre el peso y sobre el estilo de Clerkship, con modo claro y oscuro.

9 ¿Cómo se despliega un cambio?

Un cambio en la rama principal dispara Cloud Build, que construye el contenedor y lo publica en Cloud Run; Vercel publica el frontend. Los cambios de base de datos son migraciones aditivas de Alembic, aplicadas a Supabase.

PREGUNTAS PROBABLES

Sobre validación, metodología y alcance

1 ¿Por qué validación por expertos y no bancos de preguntas como MedQA?

Esos bancos miden al modelo de lenguaje, no a la plataforma. Lo que importa aquí es si los casos son clínicamente pertinentes y si la evaluación es justa, y eso lo juzga un profesional. Por eso el enfoque es mixto: juicio de expertos más mediciones técnicas.

2 ¿Qué es la V de Aiken?

Un índice de 0 a 1 del acuerdo de los expertos en que un ítem es adecuado: $V = S / (n \cdot (c - 1))$. Lo reportamos con su intervalo de confianza del 95 % (Penfield y Giacobbi) y lo combinamos con el I-CVI, la proporción de expertos que califican 3 o 4. Un ítem es válido si la V alcanza el criterio (0,70 u 0,80) y el I-CVI llega a 0,78 con seis o más expertos, o a 1 con menos.

3 ¿Cuántos expertos tendrán?

La sección 7.5 plantea al menos dos expertos clínicos. [Completar con el número y los perfiles que acuerden con el director.]

4 ¿Por qué el puntaje del experto es a ciegas?

Para que la nota de la plataforma no influya en su juicio. Si la viera antes, tendería a acercarse a ella y la concordancia saldría inflada. Con los dos puntajes independientes calculamos la diferencia media y los límites de acuerdo de Bland-Altman.

5 ¿Ya lo probaron con estudiantes?

Todavía no. Los formularios de opinión de 1 a 5 están listos en cada sección y las pruebas con un grupo real son el siguiente paso, junto con el panel de expertos.

6 ¿En qué nivel de madurez está?

El proyecto apunta a TRL 4: un prototipo completo, con los tres agentes integrados, evaluado en entorno controlado.

7 ¿Por qué solo gastroenterología?

Es la delimitación del proyecto: ocho subtemas de un mismo sistema permiten casos coherentes y una rúbrica comparable. La arquitectura no depende del sistema orgánico, así que extenderlo es cuestión de catálogo y de validación clínica.

8 ¿En qué se diferencia de los simuladores que ya existen?

El paciente conversa en lenguaje libre y en español, los casos se generan en lugar de seguir un guion fijo, y la retroalimentación desglosa el proceso de razonamiento por dimensión, no solo el diagnóstico final. Además se integra con un aula virtual para el docente.

9 ¿Qué quedó fuera del alcance?

La detección de sesgos cognitivos, porque identificarlos en una sola conversación exige criterios validados; la búsqueda vectorial; y la papelera de la nube personal.

PARA TENER A MANO

Cifras clave

DATO	VALOR
Pruebas automatizadas del backend	848 aprobadas, 10 omitidas, 0 fallos
Rutas de la API	216, ninguna sin control de rol o de propiedad
Robustez del paciente (24 intentos)	100 % sin fuga del diagnóstico y sin romper el papel
Consistencia de la nota (5 consultas × 3 evaluaciones)	5 de 5 con ≤ 10 puntos; diferencia máxima 6
Latencia, percentil 90	4,7 s el chat; 8,0 s la evaluación
Evaluación antes y después de corregir la latencia	unos 100 s → menos de 10 s
Pesos de la nota	Anamnesis 30 %, razonamiento 25 %, hallazgos 20 %, examen y paraclínicos 15 %, comunicación 10 %
Biblioteca	433 recursos (38 libros, 75 guías, 170 ensayos, 30 protocolos, 120 casos)
Carga inicial del frontend	de 3,1 MB a unos 200 KB
Validación por expertos	32 ítems de 1 a 4 y 8 criterios por caso; sin respuestas reales aún

Fuente: documento de grado PGI_59554, actualizado al 28 de octubre de 2026.